TRƯỜNG ĐẠI HỌC BÁCH KHOA, ĐHQG-HCM
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH

PHIẾU ĐỀ TÀI · ĐỒ ÁN TỔNG HỢP CO3101

Nhóm 02 · An toàn thông tin và học máy · học kỳ 261 · giảng viên hướng dẫn: TS. Nguyễn An Khương

Mục	Nội dung
Mã đề tài	C1
Tên tiếng Việt	Phát hiện URL lừa đảo: bao nhiêu phần của con số 99 phần trăm là do cách dựng dữ liệu
Tên tiếng Anh	Phishing URL detection: how much of the reported 99 percent comes from dataset construction
Sinh viên	2452657 Khiếu Tùng Lâm 2452331 Lê Mai Minh Hiếu
Quy mô	1 tín chỉ · độ khó 3/5 · tiềm năng bài báo: Trung bình
Giờ người ước lượng	bắt buộc 105 giờ; 4,8 giờ mỗi sinh viên mỗi tuần; trần của một tín chỉ là 50 tới 60 giờ mỗi sinh viên

1. Bài toán

Phần lớn báo cáo phát hiện lừa đảo đạt trên 99 phần trăm rồi sập khi gặp dữ liệu mới. Bốn nguyên nhân đã được ghi trong tài liệu: chia ngẫu nhiên làm rò rỉ tương lai vào quá khứ; lấy mẫu âm từ danh sách trang phổ biến nên mô hình học độ dài URL thay vì dấu hiệu lừa đảo; đo bằng độ chính xác trên tập cân bằng nhân tạo; và thứ tư, đặc trưng được tính từ chính nhãn, cộng với mẫu âm dựng theo một khuôn URL duy nhất, khiến một luật một dòng đã đủ đạt gần 99 phần trăm.

2. Câu hỏi nghiên cứu

Khi thay chia ngẫu nhiên bằng chia tách rời theo tên miền đăng ký (eTLD+1), và khi loại các đặc trưng được tính từ chính nhãn, hiệu năng của cùng một mô hình tụt bao nhiêu, và bao nhiêu phần của con số 99 phần trăm đã công bố là do cách dựng bộ dữ liệu chứ không do khả năng phát hiện?

3. Dữ liệu và giấy phép

PhiUSIIL (UCI 967, CC BY 4.0, 235.795 URL trong đó 134.850 hợp lệ và 100.945 lừa đảo, 54 đặc trưng). Bộ này KHÔNG có trường thời gian, đã kiểm danh sách 56 cột trên API của UCI, nên không chia theo thời gian được và không tính AUT được: chia tách rời theo eTLD+1 là phương án chính ngay từ W4. Bộ Kaggle Malicious URLs chỉ dùng kiểm chéo, và chỉ trên tập con đặc trưng từ vựng tính lại được từ chuỗi URL, dự kiến 7 tới 11 đặc trưng, phải liệt kê đúng danh sách đó trong báo cáo trước khi so.

4. Baseline bắt buộc

Luật một dòng làm sàn dưới: gắn cờ URL nào không khớp mẫu https://www.tên-miền, vì toàn bộ 134.850 URL hợp lệ trong PhiUSIIL theo đúng khuôn đó; hồi quy logistic trên đặc trưng từ vựng; gradient boosting; và chính mô hình đó dưới chia ngẫu nhiên để làm đối chứng

Một đồ án không có baseline thì không có gì để so, và con số đẹp tới đâu cũng không nói lên điều gì.

5. Chỉ số đo

Precision, Recall, F1, PR-AUC ở tỉ lệ dương thực tế; hiệu năng của luật một dòng làm sàn dưới; độ quan trọng đặc trưng

6. Kiểm thử bắt buộc

Ba kiểm thử: (1) hàm chia theo eTLD+1 không để hai URL cùng tên miền đăng ký nằm ở hai phía, kiểm trên dữ liệu giả 20 dòng; (2) hàm tính PR-AUC khớp sklearn trên một vector đã biết; (3) hàm hạ tỉ lệ dương giữ nguyên toàn bộ số mẫu dương.

Ba kiểm thử này chấm 15 điểm trong tiêu chí A3. Chúng bắt loại lỗi không làm chương trình sập mà chỉ làm con số sai, và đó đúng là loại lỗi mà đồ án dạng này hay mắc.

7. Sản phẩm phải nộp

Kho mã, bảng so sánh hai cách chia, danh sách đặc trưng gây rò rỉ, và một câu trả lời thẳng cho câu hỏi con số 99 phần trăm

Phạm vi tối thiểu, tức phần còn lại nếu cắt hết phần mở rộng: Một bảng so sánh chia ngẫu nhiên đối chia theo eTLD+1 trên một mô hình duy nhất, cộng hiệu năng của luật một dòng.

8. Mốc tuần

W4 tải dữ liệu, xác nhận bằng pd.read_csv(...).columns rằng không có cột thời gian, chạy luật một dòng; W5 dựng sơ đồ chia theo eTLD+1; W7 bảng đối chứng hai cách chia; W9 kiểm toán đặc trưng rò rỉ; W11 chốt; W12 tuần đệm; W14 nộp. W6, W8, W10 không có mốc mới: dùng để vá mốc tuần trước, viết kiểm thử và cập nhật sổ artifact.

9. Cổng đi tiếp hay dừng

Tới hết W5: ít nhất một sơ đồ chia không rò rỉ chạy từ đầu tới cuối và cho ra một con số F1, dù xấu. Không đạt thì chuyển sang C3, quyết ngay trong tuần đó. Tới hết W7: có bảng đối chứng hai cách chia trên cùng một mô hình. Không đạt thì bỏ phần kiểm toán đặc trưng, chỉ báo cáo phần đối chứng.

10. Rủi ro và cách chặn

Nhóm chưa ai làm dự án AI: hai tuần đầu ép chạy được baseline, không đọc lý thuyết trước. · Kaggle không trả metadata cho máy: kiểm tay khi tải. · Kết quả có thể là mô hình học máy không hơn luật một dòng: đó là kết quả hợp lệ và là kết quả tốt, không được giấu.

11. Phân công

Sinh viên	Phần việc
Khiếu Tùng Lâm 2452657	Miền bài toán: chọn đặc trưng, đọc và giải thích các nhóm URL, phân tích lỗi
Lê Mai Minh Hiếu 2452331	Thiết kế thí nghiệm và thống kê: hai sơ đồ chia, đo ở tỉ lệ dương thực tế, khoảng tin cậy

12. Tài liệu phải đọc

Arp et al., USENIX Security 2022 (mười cạm bẫy); Pendlebury et al., USENIX Security 2019 (TESSERACT); El Aassal et al., IEEE Access 2020 (cạm bẫy riêng của bài toán lừa đảo); ba kiểm chứng độc lập trên GitHub về rò rỉ nhãn trong PhiUSIIL: itsprofarul/phishing-attribution-consistency, awesomedudeworld13/phish-drift, fundthmcalculus/grad-school PR 248 (tài liệu xám, phải tự đối chiếu lại trước khi trích)

13. Ghi chú của giảng viên

Ghép cặp bù nhau: một người có miền, một người có phương pháp. Cả hai đều chưa có dự án AI nào nên tuần 4 và tuần 5 phải ép chạy được baseline.

Sinh viên ký xác nhận đã đọc và đồng ý phạm vi: .....

Ngày: ...../...../2026